프로젝트 기반 빅데이터 서비스 솔루션 개발 전문 과정

교과목명 : 머신러닝알고리즘 이해 및 활용

- 평가일 : 03.10
- 성명 : 권혁종
- 점수 : 70

Q1. iris data를 불러와서 아래 사항을 수행하세요.(15점)

- 결정트리 모델을 시각화하고 주요한 인사이트를 기술하세요.(tree.plot_tree or tree.export_graphviz 이용)
- Feature importance를 추출하고 시각화하세요. 10

In [14]:

```
import warnings
warnings.filterwarnings('ignore')
from sklearn.datasets import load_iris
from sklearn.tree import DecisionTreeClassifier
from sklearn import tree
from sklearn.model_selection import train_test_split
import matplotlib.pyplot as plt
import pandas as pd
import graphviz

dataset = load_iris()
df_iris = pd.DataFrame(data=dataset.data,columns = dataset.fe
y = dataset.target

dt_clf = DecisionTreeClassifier(random_state =132,max_depth=3
X_train,X_test,y_train,y_test = train_test_split(df_iris,y,te
dt_clf.fit(X_train,y_train)

data = tree.export_graphviz(decision_tree=dt_clf,
                            feature_names=dataset.feature_nam
graphviz.Source(data)

# petal의 너비와 길이로 3개의 품종이 대부분 가려진다.
```

```
<graphviz.sources.Source at 0x1d9ef7020d0>
```

In [15]:

```
import seaborn as sns
print(dt_clf.feature_importances_)
print(dataset.feature_names)

plt.figure(figsize=(10,6))
sns.barplot(dt_clf.feature_importances_,dataset.feature_names
```

```
[0.        0.        0.3998127 0.6001873]
['sepal length (cm)', 'sepal width (cm)', 'petal le
ngth (cm)', 'petal width (cm)']
```

```
<AxesSubplot:>
```

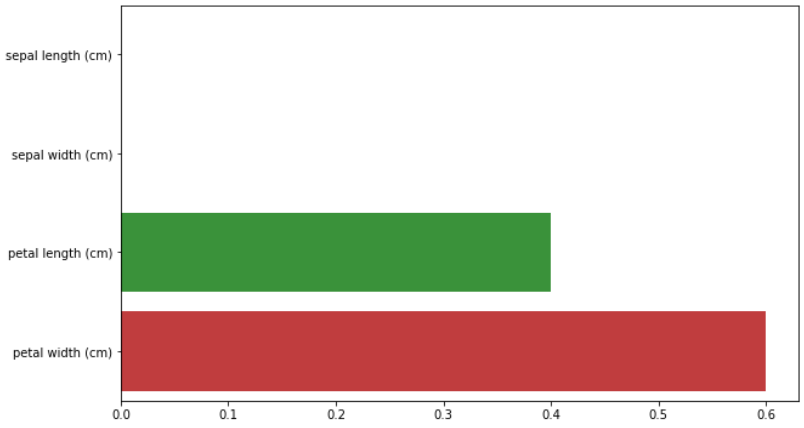

Q2~Q3. 'dataset/creditcard.csv'를 불러와서 신용카드 사기 검출 분류문제를 아래와 같이 수행하세요(10점) 10

- 로지스틱 리그레션을 적용한 모델 학습 및 사용자 함수를 이용하여 평가
  - 인자로 입력받은 DataFrame을 복사한 뒤 Time 칼럼만 삭제하고 복사된 df 반환하는 사용자 함수 생성
  - 사전 데이터 가공 후 학습과 테스트 데이터 세트를 반환하는 함수(테스트 사이즈 0.3)
  - 오차행렬, 정확도, 정밀도, 재현율, f1, AUC 평가 함수
- 인자로 사이킷런의 Estimator 객체와 학습/테스트 데이터 세트를 입력 받아서 학습/예측/평가 수행

- 사용자 함수를 사용하여 LightGBM으로 모델을 학습한 뒤 별도의 테스트 데이터 세트에서 예측 평가를 수행. 단, n_estimators=1000, num_leaves=64 적용
  ※ 레이블 값이 극도로 불균형한 분포를 가지고 있는 경우 boost_from_average=False로 파라미터 설정(default=True). default 설정은 재현율, AUC 성능을 매우 크게 저하시킴
- 넘파이의 np.log1p( )를 이용하여 Amount를 로그 변환하는하는 사용자 함수 생성
- Amount를 로그 변환 후 로지스틱 회귀 및 LightGBM 수행.

In [16]:

```
df = pd.read_csv('../../bigdatafile/creditcard.csv')
df.head()
```

	Time	V1	V2	V3	V4	V5
0	0.0	-1.359807	-0.072781	2.536347	1.378155	-0.3
1	0.0	1.191857	0.266151	0.166480	0.448154	0.0(
2	1.0	-1.358354	-1.340163	1.773209	0.379780	-0.5
3	1.0	-0.966272	-0.185226	1.792993	-0.863291	-0.(
4	2.0	-1.158233	0.877737	1.548718	0.403034	-0.4

5 rows × 31 columns

In [17]:

```
from sklearn.metrics import confusion_matrix,accuracy_score,p
def timedrop(df):
    df1 = df.drop('Time',axis=1)
    return df1
def datasplit(df):
    df = timedrop(df)
    X = df.drop('Class',axis=1)
    y = df['Class']
    X_train,X_test,y_train,y_test = train_test_split(X,y,test_
    return X_train,X_test,y_train,y_test
def scores(y_test,pred=None,pred_proba=None):
    con = confusion_matrix(y_test,pred)
    acc = accuracy_score(y_test,pred)
    pre = precision_score(y_test,pred)
    rec = recall_score(y_test,pred)
    f1 = f1_score(y_test,pred)
    roc = roc_auc_score(y_test,pred_proba)
    print(f'혼동행렬 : ₩n {con} ₩n정확도 : {acc:0.4f}, 정밀도
```

In [18]:

```
from sklearn.linear_model import LogisticRegression
lr = LogisticRegression()
X_train,X_test,y_train,y_test = datasplit(df)
lr.fit(X_train,y_train)
pred = lr.predict(X_test)
pred_proba = lr.predict_proba(X_test)[:,1]
scores(y_test,pred,pred_proba)
```

```
혼동행렬 :
 [[85262    21]
 [   59   101]]
정확도 : 0.9991, 정밀도 : 0.8279, 재현율 : 0.6312,
f1_score : 0.7163, roc_auc : 0.9794
```

- 인자로 사이킷런의 Estimator 객체와 학습/테스트 데이터 세트를 입력 받아서 학습/예측/평가 수행
  - 사용자 함수를 사용하여 LightGBM으로 모델을 학습한 뒤 별도의 테스트 데이터 세트에서 예측 평가를 수행. 단, n_estimators=1000, num_leaves=64 적용
    ※ 레이블 값이 극도로 불균형한 분포를 가지고 있는 경우 boost_from_average=False로 파라미터 설정(default=True). default 설정은 재현율, AUC 성능을 매우 크게 저하시킴
  - 넘파이의 np.log1p( )를 이용하여 Amount를 로그 변환하는하는 사용자 함수 생성
  - Amount를 로그 변환 후 로지스틱 회귀 및 LightGBM 수행.

In [21]:

```
from lightgbm import LGBMClassifier
def lgbm_score(Estimator,X_train,X_test,y_train,y_test):
    lgbm = Estimator(n_estimators=1000,num_leaves=64,boost_fr
    lgbm.fit(X_train,y_train,early_stopping_rounds=100,eval_s
    pred = lgbm.predict(X_test)
    pred_proba = lgbm.predict_proba(X_test)[:,1]
    scores(y_test,pred,pred_proba)
def lr_score(X_train,X_test,y_train,y_test):
    lr = LogisticRegression()
    lr.fit(X_train,y_train)
    pred = lr.predict(X_test)
    pred_proba = lr.predict_proba(X_test)[:,1]
    scores(y_test,pred,pred_proba)
```

In [22]:

```
lgbm_score(LGBMClassifier,X_train,X_test,y_train,y_test)
```

```
[1]     valid_0's binary_logloss: 0.598338
[2]     valid_0's binary_logloss: 0.520691
[3]     valid_0's binary_logloss: 0.455945
[4]     valid_0's binary_logloss: 0.401208
[5]     valid_0's binary_logloss: 0.354459
[6]     valid_0's binary_logloss: 0.314194
[7]     valid_0's binary_logloss: 0.279262
[8]     valid_0's binary_logloss: 0.248795
[9]     valid_0's binary_logloss: 0.222103
[10]    valid_0's binary_logloss: 0.198622
[11]    valid_0's binary_logloss: 0.177893
[12]    valid_0's binary_logloss: 0.159544
[13]    valid_0's binary_logloss: 0.143267
[14]    valid_0's binary_logloss: 0.128787
[15]    valid_0's binary_logloss: 0.11588
[16]    valid_0's binary_logloss: 0.10436
[17]    valid_0's binary_logloss: 0.0940656
```

- 넘파이의 np.log1p( )를 이용하여 Amount를 로그 변환하는하는 사용자 함수 생성
  - Amount를 로그 변환 후 로지스틱 회귀 및 LightGBM 수행.

In [23]:

```
import numpy as np
def log_amount(df):
    df['Amount'] = np.log1p(df['Amount'])
    return df
df = log_amount(df)
X_train,X_test,y_train,y_test = datasplit(df)
lr_score(X_train,X_test,y_train,y_test)
```

```
혼동행렬 :
 [[85266    17]
 [   64    96]]
정확도 : 0.9991, 정밀도 : 0.8496, 재현율 : 0.6000,
f1_score : 0.7033, roc_auc : 0.9774
```

In [24]:
```
lgbm_score(LGBMClassifier,X_train,X_test,y_train,y_test)
```

```
[1]     valid_0's binary_logloss: 0.598338
[2]     valid_0's binary_logloss: 0.520691
[3]     valid_0's binary_logloss: 0.455945
[4]     valid_0's binary_logloss: 0.401208
[5]     valid_0's binary_logloss: 0.354459
[6]     valid_0's binary_logloss: 0.314194
[7]     valid_0's binary_logloss: 0.279262
[8]     valid_0's binary_logloss: 0.248795
[9]     valid_0's binary_logloss: 0.222103
[10]    valid_0's binary_logloss: 0.198622
[11]    valid_0's binary_logloss: 0.177893
[12]    valid_0's binary_logloss: 0.159544
[13]    valid_0's binary_logloss: 0.143267
[14]    valid_0's binary_logloss: 0.128787
[15]    valid_0's binary_logloss: 0.11588
[16]    valid_0's binary_logloss: 0.10436
[17]    valid_0's binary_logloss: 0.0940656
```

Q4. Q2 신용카드 사기 검출 분류문제에서 아래를 참고하여 이상치 데이터를 제거하고 모델 학습/예측/평가를 수행하세요(5점)2.5

- 히트맵을 이용해 레이블과의 상관성을 시각화
- 레이블과 상관성이 높은 피처를 위주로 이상치 검출하는 사용자 함수 생성
- 사용자 함수를 이용하여 이상치 검출
- 이상치 제거 사용자 함수를 이용하여 이상치 제거 후 로지스틱 회귀 및 LightGBM 수행 및 평가

In [25]:

```
plt.figure(figsize = (10,10))
sns.heatmap(df.corr())
```

<AxesSubplot:>

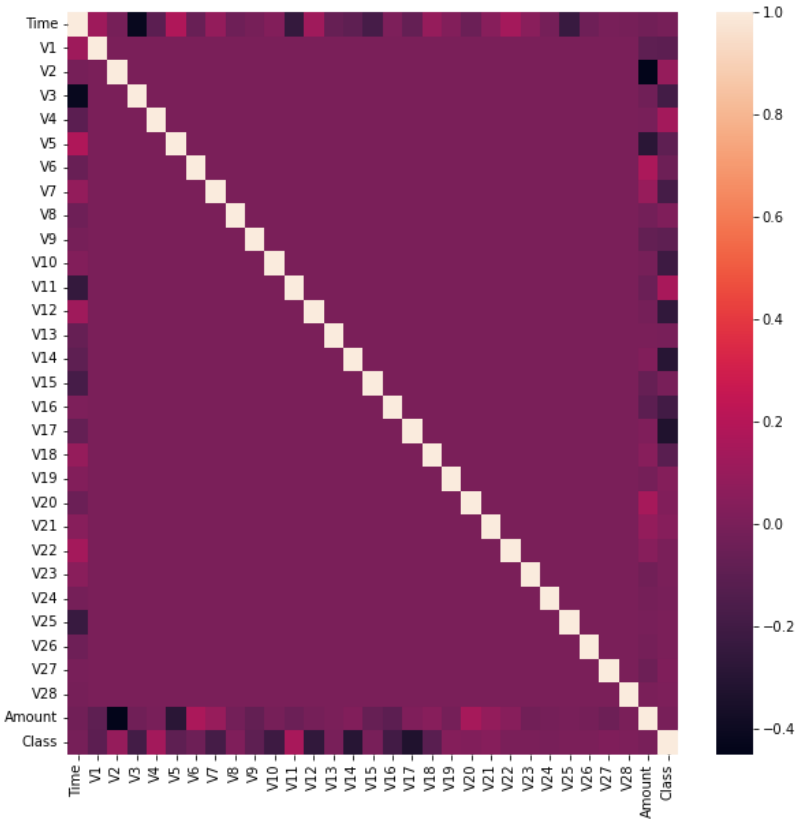

Q5. SMOTE 오버 샘플링 적용 후 LightGBM 모델을 이용하여 학습, 예측, 평가를

수행하세요.(10점)0

Q6. 사이킷런에서 제공해주는 load_boston 데이터셋을 가져와서 아래 사항을 수행하세요.(10점)7.5

- 데이터셋의 타겟 이름을 'PRICE'로 지정한 후 데이터프레임을 생성 pickle 파일로 저장 후 다시 불어오세요.
- 히트맵을 이용하여 타겟과 상관관계가 높은 독립 변수를 선택하세요.
- 종속변수를 로그 변환하세요
- 위의 사항을 반영하여 선회회귀 모델을 생성 후 평가하고 회귀계수를 출력하세요.

In [26]:

```
def score_r(y_test,y_pred):
    mse = mean_squared_error(y_test,pred)
    rmse = np.sqrt(mse)
    r2 = r2_score(y_test,pred)
    print(f'mse : {mse}, rmse : {rmse}, r2_score = {r2}')
```

In [27]:

```
from sklearn.datasets import load_boston
data = load_boston()
dt_boston = pd.DataFrame(data=data.data,columns=data.feature_
dt_boston['PRICE'] = data.target
dt_boston.to_pickle('df_boston.pkl')
dt_boston = pd.read_pickle('df_boston.pkl')
```

In [28]:

```
corr = abs(dt_boston.corr()['PRICE']).sort_values()
corr
# LSTAT이 가장 상관관계가 높음
corr_list = ['LSTAT','RM','PTRATIO','INDUS','TAX','NOX','CRIM
```

In [29]:

```
for i in corr_list:
    dt_boston[i] = np.log1p(dt_boston[i])
```

In [30]:

```
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error,r2_score
lr = LinearRegression()
X = dt_boston.drop('PRICE',axis =1)
y = dt_boston['PRICE']
X_train,X_test,y_train,y_test = train_test_split(X,y,test_siz
lr.fit(X_train,y_train)
pred = lr.predict(X_test)
score_r(y_test,pred)
lr.coef_
```

```
mse : 22.90005366375451, rmse : 4.785400052634524,
r2_score = 0.7166819952083142
```

```
array([-7.83578619e-01,  1.29761670e-02, -1.4989358
3e-01,  8.11800078e-01,
       -1.82092594e+01,  2.04147942e+01,  2.7459393
6e-02, -1.17203777e+00,
        2.66279721e+00, -3.65209147e+00, -1.6340890
6e+01,  3.65588222e-03,
       -1.06672191e+01])
```

Q7. house_df.pkl 데이터셋을 불러와서 아래사항을 수행하세요.(15점) 10

- alphas = [0, 0.1, 1, 10, 100] 를 적용하여 Ridge 회귀 모델링 및 교차 검증 수행 후 5 폴드 평균 RMSE 출력
- lasso_alphas = [0.07,0.1,0.5,1,3] 를 적용, Lasso 회귀 모델링 및 교차 검증 수행 후 5 폴드 평균 RMSE 출력(def get_linear_reg_eval(model_name,params=None,X_data_n=None, y_target_n=None, verbose=True 사용자 함수 이용)
- elastic_alphas = [0.07,0.1,0.5,1,3] 를 적용, ElasticNet 회귀 모델링 및 교차검증 후 5 폴드 평균 RMSE를 출력(사용자 함수 이용)

In [31]:

```
house_df = pd.read_pickle('./dataset/house_df.pkl')
house_df.head()
```

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	D
0	0.00632	18.0	2.31	0.0	0.538	6.575	65.2	4.
1	0.02731	0.0	7.07	0.0	0.469	6.421	78.9	4.
2	0.02729	0.0	7.07	0.0	0.469	7.185	61.1	4.
3	0.03237	0.0	2.18	0.0	0.458	6.998	45.8	6.
4	0.06905	0.0	2.18	0.0	0.458	7.147	54.2	6.

In [32]:

```
X = house_df.drop('PRICE',axis=1)
y = house_df['PRICE']
```

In [33]:

```
from sklearn.linear_model import Ridge,Lasso,ElasticNet
from sklearn.model_selection import cross_val_score
alphas = [0, 0.1, 1, 10, 100]
lasso_alphas = [0.07,0.1,0.5,1,3]
elastic_alphas = [0.07,0.1,0.5,1,3]
rmse_list = []
for i in alphas:
    ridge = Ridge(alpha=i)
    score = cross_val_score(ridge,X,y,scoring='neg_mean_squar
    rmse_list.append(np.sqrt(-1*score.mean()))
    print('alpha : ', i)
    print(np.mean(rmse_list))
```

```
alpha :  0
6.093587405436876
alpha :  0.1
6.0761106775700435
alpha :  1
6.030267081364914
alpha :  10
5.967415344755178
alpha :  100
5.8676543967752846
```

In [37]:

```
# lasso_alphas = [0.07,0.1,0.5,1,3] 를 적용, Lasso 회귀 모델릉
# (def get_linear_reg_eval(model_name,params=None,X_data_n=Noı
def get_linear_reg_eval(model_name,params=None,X_data_n=None,
    rmse_list = []
    for i in params:
        clf = model_name(alpha = i)
        score = cross_val_score(clf,X_data_n,y_target_n,scori
        rmse_list.append(np.sqrt(-1*score.mean()))
        print('alpha : ', i)
        print(np.mean(rmse_list))
get_linear_reg_eval(Lasso,lasso_alphas,X,y)
```

```
alpha :  0.07
5.907231325847088
alpha :  0.1
5.9044813121103505
alpha :  0.5
5.898013011177185
alpha :  1
5.913719060391647
alpha :  3
6.0055156363797835


[Parallel(n_jobs=1)]: Using backend SequentialBacke
nd with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done   5 out of   5 | elapse
d:    0.0s finished
[Parallel(n_jobs=1)]: Using backend SequentialBacke
nd with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done   5 out of   5 | elapse
d:    0.0s finished
[Parallel(n_jobs=1)]: Using backend SequentialBacke
nd with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done   5 out of   5 | elapse
d:    0.0s finished
[Parallel(n_jobs=1)]: Using backend SequentialBacke
nd with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done   5 out of   5 | elapse
d:    0.0s finished
[Parallel(n_jobs=1)]: Using backend SequentialBacke
nd with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done   5 out of   5 | elapse
d:    0.0s finished
```

In [38]:

```
get_linear_reg_eval(ElasticNet,elastic_alphas,X,y)
```

```
alpha :  0.07
5.746594668577731
alpha :  0.1
5.724713027648879
alpha :  0.5
5.667484785929898
alpha :  1
5.666013042042827
alpha :  3
5.757869445644106


[Parallel(n_jobs=1)]: Using backend SequentialBacke
nd with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done   5 out of   5 | elapse
d:    0.0s finished
[Parallel(n_jobs=1)]: Using backend SequentialBacke
nd with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done   5 out of   5 | elapse
d:    0.0s finished
[Parallel(n_jobs=1)]: Using backend SequentialBacke
nd with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done   5 out of   5 | elapse
d:    0.0s finished
[Parallel(n_jobs=1)]: Using backend SequentialBacke
nd with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done   5 out of   5 | elapse
d:    0.0s finished
[Parallel(n_jobs=1)]: Using backend SequentialBacke
nd with 1 concurrent workers.
[Parallel(n_jobs=1)]: Done   5 out of   5 | elapse
d:    0.0s finished
```

Q8. load_boston 데이터셋을 불러와서 다음사항을 수행하세요.0

- SVM 알고리즘을 활용한 주택가격 예측모델 생성 및 평가(MSE, RMSE, R2)
- 개발된 예측모델을 활용하여 아래 test_data가 주어졌은때의 주택가격 예측
  test_data = [3.7, 0, 18.4, 1, 0.87, 5.95, 91, 2.5052, 26, 666, 20.2, 351.34, 15.27]

In [ ]:

```
1
```

Q9. mtcars 데이터셋(mtcars.csv)의 qsec 컬럼을 최소최대 척도(Min-Max Scale)로 변환한 후 0.5보다 큰 값을 가지는 레코드 수를 구하시오 10

In [22]:

```
from sklearn.preprocessing import MinMaxScaler
scaler = MinMaxScaler()
mtcars = pd.read_csv('./dataset/mtcars.csv')
mtcars['qsec'] = scaler.fit_transform(mtcars[['qsec']])
mtcars.loc[mtcars.qsec>0.5].count()
# 9개
```

```
Unnamed: 0    9
mpg           9
cyl           9
disp          9
hp            9
drat          9
wt            9
qsec          9
vs            9
am            9
gear          9
carb          9
dtype: int64
```

Q10. purdata.csv는 백화점 고객의 1년 간 구매 데이터이다. 아래사항을 수행하세요.10

- 남성고객을 분류하는 모델을 생성(분류알고리즘 : dt,rf,lr)
- 모델 성능을 roc_auc로 평가

In [23]:

```
1 purdata = pd.read_csv('./dataset/purdata.csv')
2 purdata.head()
```

	cust_id	총구매액	최대구매액	환불금액	주구매상품	주구매지점	내점일수
0	0	68282840	11264000	6860000.0	기타	강남점	19
1	1	*	2136000	300000.0	스포츠	잠실점	2
2	2	3197000	1639000	NaN	남성캐주얼	관악점	2
3	3	*	4935000	NaN	기타	광주점	18
4	4	29050000	24000000	NaN	보석	본점	2

In [24]:

```
def get_catmax(X,c1,c2,c3):
    cat = ''                #여기에 저장됨
    if X < c1 : cat = 1
    elif X < c2: cat = 2
    elif X < c3: cat = 3
    else:
        cat = 4
    return cat
def get_cat(df,column):
    c = df[column]
    c1 = np.percentile(c,25)
    c2 = np.percentile(c,50)
    c3 = np.percentile(c,75)
    df[column] = df[column].apply(lambda X : get_catmax(X,c1,
```

In [25]:

```
purdata['총구매액'].replace('*',np.nan ,inplace=True)
purdata.dropna(subset='총구매액',inplace=True)
purdata.drop('cust_id',axis=1,inplace=True)
purdata.총구매액.astype(float)
```

```
0        68282840.0
2         3197000.0
4        29050000.0
5        11379000.0
6        10056000.0
            ...
3495      3175200.0
3496     29628600.0
3497        75000.0
3498      1875000.0
3499    263101550.0
Name: 총구매액, Length: 3498, dtype: float64
```

In [51]:

```
from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
purdata['주구매상품'] = le.fit_transform(purdata['주구매상품'
purdata['주구매지점'] = le.fit_transform(purdata['주구매지점'

purdata.head()
```

	총구매액	최대구매액	환불금액	주구매상품	주구매지점	내점일수	내점당구매건수
0	68282840	11264000	6860000.0	5	0	19	3.894737
2	3197000	1639000	NaN	6	1	2	2.000000
4	29050000	24000000	NaN	15	8	2	1.500000
5	11379000	9552000	462000.0	11	18	3	1.666667
6	10056000	7612000	4582000.0	22	0	5	2.400000

In [52]:

```
purdata.환불금액.fillna(0,inplace = True)
purdata['환불금액'] = np.where(purdata.환불금액 == 0 ,0,1)
```

In [56]:

```
get_cat(purdata,'최대구매액')
```

In [65]:

```
def modelscores(model,X_train,X_test,y_train,y_test):
    model.fit(X_train,y_train)
    pred = model.predict(X_test)
    pred_proba = model.predict_proba(X_test)[:,1]
    con = confusion_matrix(y_test,pred)
    acc = accuracy_score(y_test,pred)
    pre = precision_score(y_test,pred)
    rec = recall_score(y_test,pred)
    f1 = f1_score(y_test,pred)
    roc = roc_auc_score(y_test,pred_proba)
    print(f'모델 : {model} Wn혼동행렬 : Wn {con} Wn정확도 : {
```

In [66]:

```
from sklearn.ensemble import RandomForestClassifier
dt = DecisionTreeClassifier()
rf = RandomForestClassifier()
lr = LogisticRegression()
X_train,X_test,y_train,y_test = train_test_split(purdata.drop
modelscores(dt,X_train,X_test,y_train,y_test)
modelscores(rf,X_train,X_test,y_train,y_test)
modelscores(lr,X_train,X_test,y_train,y_test)
```

```
모델 : DecisionTreeClassifier()
혼동행렬 :
 [[266 170]
 [150 114]]
정확도 : 0.5429, 정밀도 : 0.4014, 재현율 : 0.4318,
f1_score : 0.4161, roc_auc : 0.5210

모델 : RandomForestClassifier()
혼동행렬 :
 [[340  96]
 [167  97]]
정확도 : 0.6243, 정밀도 : 0.5026, 재현율 : 0.3674,
f1_score : 0.4245, roc_auc : 0.6168

모델 : LogisticRegression()
혼동행렬 :
 [[435   1]
 [264   0]]
정확도 : 0.6214, 정밀도 : 0.0000, 재현율 : 0.0000,
f1_score : 0.0000, roc_auc : 0.6191
```